

Plano Completo do Projeto ETL - COVID Data Pipeline

Este documento apresenta um planejamento completo para o desenvolvimento do projeto COVID Data Pipeline utilizando Python, SQL e PostgreSQL. O objetivo do projeto é desenvolver conhecimentos práticos em ETL, organização de projetos, manipulação de dados, SQL e engenharia de dados.

1. Organização do Projeto

- Criar estrutura de pastas no GitHub.
- Configurar README.md e .gitignore.
- Aprender Git básico (commit, push, pull).
- Pesquisar: Git, GitHub, estrutura de projetos.

2. Configuração do Ambiente

- Instalar Python e VSCode/PyCharm.
- Criar ambiente virtual com venv.
- Instalar bibliotecas principais.
- Pesquisar: pip, virtualenv, requirements.txt.

3. Extração de Dados (Extract)

- Baixar dataset COVID.
- Ler arquivos CSV com Pandas.
- Salvar dados em data/raw/.
- Pesquisar: pandas.read_csv(), requests, APIs.

4. Exploração e Entendimento dos Dados

- Verificar colunas, tipos e valores nulos.
- Entender inconsistências.
- Criar notebook exploratório.
- Pesquisar: isnull(), describe(), duplicated().

5. Limpeza e Transformação (Transform)

- Remover valores inválidos.
- Padronizar datas.
- Tratar duplicidades.
- Pesquisar: SQL SELECT, WHERE, GROUP BY, CASE, CAST.

6. Banco de Dados PostgreSQL

- Instalar PostgreSQL.

- Criar banco e tabelas.
- Conectar Python ao banco.
- Pesquisar: pgAdmin, CREATE TABLE, INSERT.

7. Carregamento de Dados (Load)

- Enviar dados tratados para PostgreSQL.
- Criar tabelas finais.
- Pesquisar: SQLAlchemy, to_sql().

8. Consultas Analíticas

- Criar análises SQL.
- Calcular métricas e rankings.
- Pesquisar: CTE, Window Functions, agregações.

9. Dashboard

- Conectar Power BI ao PostgreSQL.
- Criar gráficos e KPIs.
- Pesquisar: Power BI básico.

10. Melhorias Futuras

- Adicionar Docker.
- Automatizar com Airflow.
- Criar logs e testes.
- Pesquisar: Docker, Airflow, pytest.

Cronograma Sugerido de Estudos

Etapa	Tempo Estimado
Git/GitHub	1 semana
Python + Pandas	2 semanas
SQL	3 a 5 semanas
PostgreSQL	1 semana
ETL básico	2 semanas
Dashboard Power BI	1 semana

Objetivo final do projeto: desenvolver um pipeline ETL funcional, organizado e profissional, demonstrando conhecimentos em Python, SQL, GitHub e Engenharia de Dados.